

Projet Étudiant : Modélisation et Analyse des Bases de Données Relationnelles, Documentaires et Graphes

Mise en situation :

Dans ce projet, vous êtes engagés en tant que data engineers pour une plateforme de streaming qui souhaite améliorer ses performances en fonction de ses usages. Vous devez proposer une modélisation adaptée et comparer l'efficacité de chaque type de base de données pour répondre aux besoins métier de l'entreprise.

L'entreprise pense à mettre en place trois types de bases de données différentes afin d'optimiser les performances et la gestion des données en fonction de cas d'utilisation spécifiques :

- **Base relationnelle (PostgreSQL)** : Idéale pour gérer des ensembles de données bien structurés et normalisés. Elle est optimisée pour les requêtes analytiques et les calculs statistiques.
- **Base documentaire (MongoDB)** : Permet de stocker des données complexes sous forme de documents JSON, ce qui simplifie la récupération rapide d'informations complètes sur un film sans nécessiter de jointures (coûteuses en performance).
- **Base graphe (Neo4j)** : Optimisée pour l'exploration des relations complexes entre les entités, elle permet d'obtenir rapidement des recommandations personnalisées basées sur les interactions entre utilisateurs, films et acteurs.

La plateforme a identifié trois types de requêtes fréquentes et critiques pour son activité :

- **Trouver les films avec une note moyenne supérieure à 4.5** : Cruciale pour proposer aux utilisateurs les films les mieux notés !
- **Récupérer toutes les informations d'un film avec ses acteurs, son directeur et ses récompenses** : Cette requête est essentielle pour afficher les fiches complètes des films aux utilisateurs.
- **Trouver des films non regardés par un utilisateur ayant des acteurs qui ont joué dans des films qu'il a déjà regardés** : Cette requête analytique permet de recommander des films en fonction des préférences des utilisateurs et des relations entre les acteurs et les films.

Vous devez également proposer trois requêtes illustrant les avantages respectifs de chaque type de base de données (une par base).

Données :

Les données fournies concernent une plateforme de films et incluent les entités suivantes :

- Films
- Acteurs et réalisateurs
- Utilisateurs

Un schéma détaillé des données est fourni en annexe.

Trois ensembles de données distincts seront mis à disposition en annexe, présentant une quantité croissante d'informations mais de qualité décroissante. L'objectif est d'évaluer comment chaque type de base de données gère des données de plus en plus volumineuses, mais potentiellement plus bruitées ou incomplètes, et d'en analyser l'impact.

Travail demandé :

Modélisation des données

- Concevoir le schéma de la base relationnelle en SQL (Postgresql).
- Concevoir le modèle document (MongoDB).
- Concevoir le modèle graphe (Neo4j).

Implémentation et peuplement des bases

- Créer et remplir chaque base de données avec les données fournies.

Exécution et comparaison de requêtes types

- Trouver les films avec une note moyenne supérieure à 4.5.
- Récupérer toutes les informations d'un film avec ses acteurs, son directeur et ses récompenses.
- Trouver des films non regardés par un utilisateur ayant des acteurs qui ont joué dans des films qu'il a déjà regardés.

Analyse des performances

- Comparer le temps d'exécution des requêtes sur chaque type de base de données.
- Analyser la facilité de requêtage et d'extensibilité pour chaque paradigme.

- Identifier les cas d'utilisation appropriés pour chaque type de base de données.

Livrables :

- Un rapport expliquant la modélisation choisie pour chaque type de base de données.
- Les scripts de création et de peuplement des bases de données.
- Les requêtes SQL, NoSQL et Cypher ainsi que l'analyse de performance.
- Une conclusion sur les avantages et inconvénients de chaque paradigme en fonction des cas d'utilisation.

Bonne exploration et bon travail !